YI-HOT · GITHUB MAIN · 2026-10-19

YiHot README · 项目展示与快速入门

由 GitHub 仓库原始 Markdown 导出；仓库版本见 CochraneK/Yi-hot。

## 目录 / Contents


为什么做 Yi-Hot? ..... 2
核心能力 ..... 2
救助儿童会方向：13 个使命主题 ..... 2
Yi-Hot 与 AIHOT：哪些是继承，哪些是定制? ..... 3
快速开始 ..... 3
架构与数据边界 ..... 4
文档导航 ..... 4
当前状态、反馈与贡献 ..... 4
许可与致谢 ..... 5





# Yi-Hot · 公益动态

## Save the Children

救助儿童会方向的儿童公益主题适配 · 机构标识归原权利人所有；本站独立维护，展示不代表官方合作或背书。

**让值得关注的公益信息，更容易被发现、理解与追踪。**

面向公益从业者、研究者与关注公共议题的读者的公益资讯聚合与 AI 辅助整理平台。

浏览线上站点 · 自行部署 · 完整维护手册 · 项目交接

MIT License | TypeScript and Node.js 24 | PostgreSQL 17 | Self-hosted with Docker Compose

> [!NOTE] 本项目是以 AIHOT 为技术基础的**独立公益领域定制版本**，不是 AIHOT 或救助儿童会的官方发行版或代表其立场的产品。本文的可视化为功能与架构**示意图**，并非真实线上页面截图。原始新闻版权归发布方所有。

## 为什么做 Yi-Hot?

公益信息散落在政府公告、社会组织网站、行业媒体、微信公众号和邮件简报里。逐个阅读费时间，直接订阅又容易被重复信息淹没。

**Yi-Hot 想减少信息搜寻和整理的重复劳动**：持续发现公开信息，区分原始发布日期与抓取时间，通过可追溯的内容分析形成动态、主题和周期性总报，帮助读者更快回到可靠的一手来源。

## 核心能力

| 发现 | 理解 | 阅读 | 持续使用 |
| --- | --- | --- | --- |
| **多渠道信源**：网站、RSS、公众号、邮件简报 | **内容处理**：去重、相关性判断、摘要、翻译与结构化标签 | **动态与热点**：按原文日期查看，保留原始来源链接 | **周报与月报**：按自然周期汇总行业信息 |
| **信源治理**：候选发现、预览、隔离启用、健康检查 | **公益语境适配**：政策、项目、机构、儿童与其他公益领域 | **主题与机构页**：按议题交叉阅读，不只依靠关键词 | **邮件订阅**：双重确认、按期投递、可退订 |
| **历史资产留存**：NewsMail 与 charity-intelligence 信源线索 | **人工可复核**：留存判断链、来源和模型用量 | **RSS / API / MCP**：向外提供标准化读取入口 | **后台运维**：异常诊断、费用管理、反馈与审计 |




**给不同读者的三个入口：** 动态 用于查看最新信息；主题 用于按领域阅读；周报 / 月报 用于回顾周期内的重要进展。

## 救助儿童会方向：13 个使命主题

Yi-Hot 针对儿童公益议题进行了领域定制：主题词表、别名映射、前台主题筛选，以及存量内容的标签回填机制。项目维护者另开展过救助儿童会微信公众号历史文章的采集与数据分析工作；**原始语料、样本规模和完整分析报告尚未在本仓库形成可独立核验的公开研究包**，因此这里不以未经核实的数量或统计结论作为宣传指标。




- 主题既用于发现信息，也用于前端导航、标签与历史文章回填；具体规则见 主题轴说明。
- **内容形式**（政策、研究、项目等）与**公益主题**（儿童保护、营养健康等）是不同维度，可以同时出现。
- “其他领域”是兜底标签，不应与明确的使命领域同时出现。标签不是科学测量结论，实际质量需要持续抽样复核。

## Yi-Hot 与 AIHOT：哪些是继承，哪些是定制？

| 层面 | 说明 |
| --- | --- |
| **继承 AIHOT 的核心底座** | 信息处理引擎、Web/API、任务调度、数据库模型及大量基础组件；保留原作者署名和许可 |
| **Yi-Hot 的公益定制** | 公益信源、领域词表、儿童议题主题轴、相关性与精选规则、公益内容文案与主题入口 |
| **Yi-Hot 的运营扩展** | WeRSS 公众号接入、QQ 邮件简报、总报邮件订阅、后台候选信源治理、云端部署与交接 |
| **跨项目资产** | NewsMail 与 charity-intelligence 的历史线索以候选形式保留；**不等于**已批准或全部接入采集 |
| **上游更新** | `main` 是现用版本；`vendor/aihot-main` 与 `rebuild/aihot-aligned` 用于隔离追踪、验证更新，**不会自动替换生产** |

详情：上游升级和重构方案 • 信息源治理原则。

## 快速开始

**前置条件：** Node.js 24.11+、Docker / Docker Compose、npm，以及可供测试的 PostgreSQL 环境。默认配置用于本机体验；真实采集、模型、公众号和邮件功能需要分别配置对应凭据与开关。

```
git clone https://github.com/CochraneK/Yi-hot.git
cd Yi-hot
npm ci
cp .env.example .env
node scripts/init-env.ts
docker compose up -d --build
```

本地通常访问 **http://localhost:3000**；后台通常为 **http://localhost:3000/admin**。不要将生产密钥复制到测试环境。详见 完整维护手册 与 部署说明。

> [!IMPORTANT] 仓库目前为 **Private**，以上克隆命令需要相应 GitHub 访问权限。若未来公开，须先排查历史提交、旧分支、凭据、第三方资产和机构品牌授权，不能只检查最新 `main`。

## 架构与数据边界

```
flowchart LR
  A["政府网站 / 公益机构 / RSS / 公众号 / 邮件"] --> B["采集与来源治理"]
  B --> C["规范化、发布时间、去重"]
  C --> D["AI 相关性判定、摘要与标签"]
  D --> E["统一发布层"]
  E --> F["动态 / 热点 / 主题"]
  E --> G["周报 / 月报"]
  G --> H["订阅确认、邮件投递与退订"]
  B -. "候选需人工审核" .-> I["历史信源线索库"]
```

**守住三条边界：** 只在允许的范围内采集；默认仅显示摘要和原文链接，不擅自转载全文；`industry/sources.json` 是 seed，**生产信源以 PostgreSQL 中的运行时配置为准**。项目不保证所有来源全天候可访问，也不保证 AI 摘要永远准确，重要事实请以原文为准。

## 文档导航

| 我要做什么 | 从这里开始 |
| --- | --- |
| **只想了解产品** | 线上站点 • 分类和标签 |
| **第一次接手维护** | 完整维护手册 • 交接总览 |
| **新增公益信源** | 信源配置 • 候选治理与核查 |
| **配置公众号和邮件** | WeRSS • 邮件采集 • 邮件发送 |
| **理解系统如何运作** | 技术架构 • 评分与筛选 |
| **同步和重新部署** | 同步工具 • 运行维护 |
| **跟踪 AIHOT 上游** | 升级与重构方案 |

## 当前状态、反馈与贡献

- **部署状态与代码状态需要分别核验。** GitHub 更新不代表腾讯云已自动部署；上线后须进行文件哈希比对和实际运行检查。
- **截至 2026-10-18，`main` 的 GitHub Actions Check 尚未全绿。** 已观察到领域标签测试预期与 seed 来源数量断言需要校正；不能将其表述为全部测试通过。查看运行记录。

- 邮件订阅与反馈涉及个人信息。公开隐私页面的运营主体与联系信息等模板字段**尚待实际维护者完善**；在正式对外推广前需要核实。
- 欢迎通过 Issues 反馈失效信源、误判、来源归属、界面可用性与安全问题（需有仓库访问权限）。不要在公开 Issue 提交密码、个人隐私或未获授权的全文数据。

## 许可与致谢

本项目基于 **KKKKhazix/AIHOT** 的 MIT 许可代码定制。感谢 AIHOT 的原始作者和开源贡献者。本仓库保留原始 LICENSE、NOTICE 和 第三方归属说明。AIHOT 的商标、名称及 Logo 不因代码许可而自动获得授权；救助儿童会及新闻来源的名称、标识和内容亦各有权利归属。

---

Yi-Hot · 少一些重复检索，多一些真正有用的信息。 | 完整维护手册

YI-HOT · GITHUB MAIN · 2026-10-19

# YiHot 维护手册 · Living Handbook

由 GitHub 仓库原始 Markdown 导出；仓库版本见 CochraneK/Yi-hot。

## 目录 / Contents


这个站现在怎么工作 2
新维护者第一次接手 3
日常维护只做这些 3
三种常见情况 4
不要直接做的事 4
备份、凭据与换电脑 4
给技术维护者的入口 5
来源、版权与 AIHOT 归属 5
技术概览 6
一、完整运行链路 6
二、后台怎么用 7
三、后台密码与凭据 8
四、模型 API 从零说明 9
五、信息源结构与新增来源 10
六、分类、主题和标签 11
七、日期和重复内容 12
八、公益总报和邮件订阅 12
九、公开 API、RSS 和 MCP 13
十、服务器容量基线 14
十一、巡检和故障处理 17
十二、本地开发、测试、同步和部署 19
十三、备份、换电脑和交接 20
十四、代码和行业配置地图 21
十五、后台所有设置逐项说明 21
十六、增加信息源的完整操作手册 24
十七、未来同步 AIHOT 上游改动 35
十八、迁移到 NAS 或另一台服务器 36
十九、常见需求该改哪里 38
二十、必须守住的安全边界 39
二十一、专题文档索引 39
二十二、持续维护规则（Living Handbook） 40
2026-10-18 本次维护变更 42

# Yi-Hot 公益动态

> **这是 Yi-Hot 的持续维护手册（Living Handbook）。** 面向日常维护者、开发者以及接手的 AI Agent；简洁项目展示见 README。完整正文保留了之前的详尽操作手册，后续功能、部署、故障与研究成果按本文末尾的「二十二、持续维护规则」增补，不以重写 README 代替更新这里。
>
> **阅读提示（2026-10-18）：** 下文的“当前信源数量”、模型价格、运营状态、服务器清单和测试结论有些是特定日期的历史快照，并不代表此刻的生产状态。生产信源以 PostgreSQL `sources` 为准；代码和测试以 GitHub `main` 为准；腾讯云部署状态要另行核验，不能从 GitHub 提交推断。尤其是 2026-10-18 后 Docker CI 的种子数量校验已改为从 `industry/sources.json` 读取，而不是固定的 20 条。



**Save the Children**

Yi-Hot 是一个公益行业动态聚合站。它定时读取政府部门、公益机构、媒体、微信公众号和邮件简报，生成中文标题与摘要，保留原文链接，并按周、按月生成「总报」。

线上站点：https://49.233.72.222/yihot/

管理后台：https://49.233.72.222/yihot/admin

> **交接给新维护者时，先读本页即可。** 日常工作通常只需要打开后台查看运行状态和信源，不需要理解模型、提示词或代码。需要技术处理时，再按文末的文档入口操作。

## 这个站现在怎么工作

```
公开信源 / 公众号 / 邮件
          ↓
    自动采集和去重
          ↓
  相关性判断、摘要和标签
          ↓
动态 — 热点 — 主题
          ↓
     每周、每月总报
```

- 「动态」是主要阅读入口，优先按**原文发布日期**排列；原文没有日期时才显示收录时间，并明确标注「收录」。
- 「精选」栏目目前隐藏，但精选状态和卡片标签仍保留，用于总报、后台判断和以后恢复。
- 周报每周生成，月报每月生成；日报已经停用。
- 网站部署在腾讯云。采集、分析和发布都在服务器上运行，维护者不需要一直开着自己的电脑。
- 微信公众号由服务器上的 WeRSS 辅助采集；QQ 邮箱中的指定简报由邮件采集服务每 30 分钟检查一次。

## 新维护者第一次接手

原维护者应通过安全方式分别交付以下内容，**不要把密码写进 README、聊天记录或 Git 仓库**：

1. 腾讯云账号或服务器 SSH 访问方式。
2. GitHub 仓库访问权限。
3. Yi-Hot 后台管理员密码。
4. 凭据归档的解密口令。
5. QQ 邮箱、微信公众平台等外部账号的必要权限。

接手后按下面顺序确认：

1. 打开线上站点，确认「动态」能正常显示。
2. 登录管理后台，查看「运行」和「信源」页面是否有连续失败。
3. 打开「总报」，确认最近一期周报或月报可以阅读。
4. 在 GitHub 确认自己能看到本仓库，但不要随意删除分支、Actions、`LICENSE` 或 `NOTICE`。
5. 把解密口令存进个人密码管理器；不要和加密文件放在同一个位置。

完成以上五项，就具备日常维护条件。

## 日常维护只做这些

| 频率 | 要看什么 | 正常表现 | 发现异常怎么办 |
| --- | --- | --- | --- |
| 每周一次 | 网站首页和动态 | 最近几天有新内容，原文链接可打开 | 去后台「运行」和「信源」查看失败原因 |
| 每周一次 | 总报 | 周报正常生成 | 记录缺失日期和页面地址，交给技术维护者检查任务队列 |
| 每月一次 | 信源健康 | 大部分启用信源为正常；个别网站偶发失败可以观察 | 同一信源连续失败多次再处理，不要立即删除 |
| 每月一次 | 用量与成本 | 费用和调用量没有突然异常增长 | 暂停异常来源或模型调用，并请技术维护者核查 |
| 增加新来源时 | 原文质量、发布日期、版权边界 | 能稳定取得标题、摘要、发布日期和原文链接 | 先作为候选试抓，不要直接开启全文展示 |

后台入口：

- **内容诊断**：查看某条动态为什么出现、为什么没有入选。
- **信源**：查看采集是否正常，也可以先试抓再决定是否启用。
- **运行**：查看自动任务成功或失败。
- **用量与成本**：查看模型调用量和费用。
- **反馈**：处理读者提交的更正、下架或其他意见。

# 三种常见情况

## 网站能打开，但最近没有新内容

先去后台检查：

1. 「信源」里最近采集是否成功；
2. 「运行」里 worker 是否持续运行；
3. 新抓到的内容是否被判断为与公益无关；
4. 原文发布日期是否确实较早。

不要把本站收录时间当成原文发布日期，也不要为了让页面看起来更新而手工改日期。

## 某个来源连续失败

先保留来源并记录错误。网站改版、验证码、登录失效和 RSS 临时中断都可能造成失败。公众号失败通常先检查 WeRSS 登录状态；邮件来源失败通常先检查 QQ 邮箱授权是否仍有效。只有确认来源永久停用或不再适合收录时才关闭。

## 需要修改页面、部署或修复程序

这属于技术维护。把问题现象、发生时间、页面地址和后台错误一起交给技术人员。若使用编码 Agent，可以直接给它下面这段话：

```
请先阅读仓库根目录 AGENTS.md、docs/PROJECT_CONTEXT.md、
docs/memory/MEMORY.md、tools/README.md 和 secrets/README.md。
先核实线上现象和运行状态，再修改、测试、同步 GitHub 并部署腾讯云。
不要输出或提交任何密钥。
```

# 不要直接做的事

- 不要把 `.env`、邮箱授权码、后台密码、SSH 密码或 API Key 提交到 GitHub。
- 不要直接改数据库里的日期、精选结果或费用记录。
- 不要因为一两次失败就删除信源或历史内容。
- 不要绕过后台和现有脚本在生产服务器上临时改代码。
- 不要随意修改模型、评分门槛或提示词；这些改动会影响全部内容，需要样本校准和测试。
- 不要删除或改写 `LICENSE`、`NOTICE` 中的上游版权信息。
- 不要使用 AIHOT 的名称或 Logo 作为 Yi-Hot 的品牌。

# 备份、凭据与换电脑

- 生产运行时凭据以服务器 `/opt/yihot/.env` 为准。
- 仓库中的 `secrets/credentials.env.enc` 是加密备份；解密口令不在仓库中。

- 明文凭据只保存在本机忽略文件和服务器，不进入 Git。
- 凭据发生变化后，要更新服务器、更新本机明文归档、重新加密并提交新的密文。
- 换电脑或交接的完整步骤见 `docs/PROJECT_CONTEXT.md` 第 8、9 节和 `secrets/README.md`。

## 给技术维护者的入口

请依次阅读：

1. `AGENTS.md`：项目规则与安全边界。
2. `docs/PROJECT_CONTEXT.md`：服务器、部署、数据口径和接手清单。
3. `docs/memory/MEMORY.md`：运维经验索引。
4. `tools/README.md`：GitHub 同步、部署和核查脚本。
5. `secrets/README.md`：凭据加密归档。
6. `docs/sources.md`：信源类型与配置。
7. `docs/selection.md`：精选判断与校准。

最低验证命令：

```
npm run typecheck
npm run build -w @aihot/web
node --test apps/web/tests/*.test.ts
```

涉及数据库行为时还要在名称以 `_test` 或 `_ci` 结尾的测试库中运行迁移和 `npm test`。本项目在当前网络环境下推送 GitHub 必须使用 `tools/sync.py`；完整说明见 `tools/README.md`。

## 来源、版权与 AIHOT 归属

**Yi-Hot 是在 AIHOT 开源项目基础上修改的公益行业定制版本。** AIHOT 由“数字生命卡兹克 / KKKKhazix”开发，代码依据 MIT License 开放。本仓库保留了上游的 `LICENSE` 和 `NOTICE`。

使用、复制、修改或再发布本项目时必须注意：

1. 按 MIT License 要求，在软件副本或主要部分中保留原版权声明和许可文本。
2. 保留 `NOTICE` 中的上游及第三方材料说明。
3. AIHOT 的名称和 Logo 不属于 MIT 授权范围；本项目使用自己的 Yi-Hot 名称和品牌，也不得让人误以为这是 AIHOT 官方站点。
4. 原始新闻、图片和文章版权归各来源所有。Yi-Hot 默认只展示摘要和原文链接，只有来源明确允许时才展示全文。
5. 新增第三方代码、图片、字体或数据前，应核对其许可证并补充相应归属说明。

本节用于帮助维护者保留清晰来源，并不替代 `LICENSE`、`NOTICE` 或专业法律意见。

## 技术概览

- Node.js 24、TypeScript、React Router、Fastify
- PostgreSQL 17、pg-boss
- Docker Compose
- 一个镜像运行 Web、API、worker 和数据库初始化任务
- 公开出口包括网站、RSS、API 和 MCP

项目内部仍保留 `aihot`、`@aihot/*` 和 `aihot-*` 等技术标识，这是为了兼容上游结构和现有部署；对外品牌始终是 **Yi-Hot**。

# 完整维护手册

下面的内容面向第一次接手、不了解 API、模型或服务器的维护者。它把日常使用、密码、模型、采集、邮件、部署和故障处理放在同一份文档中。遇到复杂改动时，再沿文中的链接阅读专题文档。

## 一、完整运行链路

```
网站 / RSS / 微信公众号 / QQ 邮件
                ↓
        定时采集、规范化、去重
                ↓
       公益相关性判断和内容分析
                ↓
     中文标题、摘要、分类、主题、标签
                ↓
    全部动态 / 主题页 / RSS / 公开 API
                ↓
          每周、每月公益总报
                ↓
     网站阅读 / 邮件订阅 / 外部程序读取
```

服务器上的 worker 持续执行这些任务。维护者关掉自己的电脑不会影响网站、公众号采集、邮件采集或总报发送。

生产服务如下：

| 服务 | 作用 | 运行方式 |
| --- | --- | --- |
| `aihot-web-1` | 网页和 SSR | Docker |
| `aihot-api-1` | 公开 API、后台 API、订阅 API | Docker |
| `aihot-worker-1` | 采集、分析、归组、发布、总报 | Docker |
| `aihot-db-1` | PostgreSQL 数据库 | Docker volume |

| 服务 | 作用 | 运行方式 |
| --- | --- | --- |
| `yihot-werss-werss-1` | 微信公众号 RSS | Docker |
| `yihot-email-source.timer` | 每 30 分钟读取获准邮件来源 | systemd |
| `yihot-email-delivery.timer` | 每 30 分钟发送确认信和总报 | systemd |

# 二、后台怎么用

后台地址是 https://49.233.72.222/yihot/admin。登录成功后浏览器保存有时效的会话 Cookie；不要在公用电脑保存登录状态。

## 信源

这里回答“平台正在从哪里取内容”。重点看启用状态、最近采集、连续失败和采集间隔。

- 新来源先预览真实标题、发布日期和原文链接。
- 初始设为暂停或隔离，确认内容范围后再改为编辑候选。
- 一两次网络超时可以观察；连续多次失败再处理。
- 不要为了增加内容量而开启全文展示或降低相关性门槛。

## 内容诊断

这里回答“某条动态为什么出现、为什么没出现”。可以查看原始文章、模型分析、发布记录、事件归组和调用回执。

- 字段错误通过后台 override 或正规回填脚本修正。
- 重新分析会产生模型费用，先确认原始数据确实有错。
- 隐藏、合并、拆分等操作要写明原因，操作会进入审计记录。

## 运行

这里回答“自动任务是否正常”。重点关注采集是否持续、是否出现成片失败、付费请求是否结果未知、投递是否需要人工处理。单次失败不一定是故障；所有来源同时停止或同类错误连续出现才需要立即处理。

## 用量与成本

这里显示模型调用数、输入/输出 token、估算费用和月化区间。费用依赖后台维护的单价；显示“未定价”不代表免费，而是模型名称没有匹配的价格记录。

平台后台预算是第一层保险丝，模型服务商控制台的余额和消费上限是第二层。任一侧达到上限都会停止相应调用。

### 模型与评测

这里能看到每类任务使用的模型、成功率、延迟、token 和费用，也可以切换模型。切换前应先配置新模型 API Key，用少量真实样本验证结构化输出，维护单价，并观察至少一个采集周期。

### 反馈与审计

反馈页用于处理读者提交的更正、下架和其他意见。审计页用于追溯管理员操作。发生误操作时应修正并说明原因，不要删除审计记录。

## 三、后台密码与凭据

### 密码在哪里

后台密码是环境变量 `ADMIN_PASSWORD`。明文不在 Git 仓库中。当前生产真值位于：

```
/opt/yihot/.env
```

仓库中的加密备份是：

```
secrets/credentials.env.enc
```

拿到原维护者单独交付的解密口令后，在仓库根目录运行：

```
bash tools/secrets.sh decrypt
```

命令会生成被 Git 忽略的 `secrets/credentials.env`。从中查看 `ADMIN_PASSWORD`。不要把这个文件、密码或屏幕截图发到聊天或提交到 GitHub。

### 忘记密码怎样重置

如果仍能登录服务器：

```
ssh <服务器用户>@<服务器地址>
cd /opt/yihot
sudoedit .env
```

把 `ADMIN_PASSWORD` 改成至少 12 位的随机密码，然后让容器重新读取 `env_file`：

```
sudo docker compose <服务器现行的完整生产覆盖参数> up -d
```

只执行 `docker restart` 不会重新读取 `.env`。验证新密码后，把新值同步进本机 `secrets/credentials.env` 并重新加密：

```
bash tools/secrets.sh encrypt
```

如果解密口令和 SSH 权限都丢失，需要先通过腾讯云控制台恢复服务器访问。加密归档没有后门。

### 各类凭据的位置

| 凭据 | 生产位置 | 用途 |
| --- | --- | --- |
| Yi-Hot 主配置 | `/opt/yihot/.env` | 后台、数据库、模型、签名、功能开关 |
| 邮件信源 | `/opt/yihot-email/.env` | QQ IMAP、来源白名单、ingest token |
| 邮件投递 | `/opt/yihot-email-delivery/.env` | QQ SMTP、发件地址、站点地址 |
| WeRSS | `/opt/werss/.env` | 管理账号、签名密钥、镜像配置 |
| 核心凭据备份 | `secrets/credentials.env.enc` | 换电脑和灾难恢复 |

服务器配置是运行时真值，加密归档是备份。凭据变更顺序是：更新服务器、重建并验证服务、更新本机明文、重新加密、只提交密文。

## 四、模型 API 从零说明

### API、Key 和 token 分别是什么

- **API** 是程序调用服务的网络接口。Yi-Hot 通过 API 自动请求模型，不是在浏览器里操作聊天网页。
- **API Key** 类似只给程序使用的密码，通常在模型服务商控制台创建。
- **Base URL** 是服务商的接口地址。
- **Model** 是具体模型名称。
- **Token** 是模型读写文本的计费单位，与 GitHub Token、后台密码不是同一种东西。

不要在聊天里发送 API Key。应直接写入服务器 `/opt/yihot/.env`，或先写入本机被忽略的凭据文件后安全部署。

### 申请和配置步骤

1. 注册 DeepSeek、阿里云百炼、智谱等支持 OpenAI 兼容接口的服务商。
2. 在服务商控制台开通模型服务并创建 API Key。
3. 充值或设置服务商侧消费上限。
4. 在服务器 `/opt/yihot/.env` 填写接口地址、Key 和模型名。
5. `docker compose up -d` 让新配置生效。
6. 去后台「运行」「模型与评测」「用量与成本」检查下一批任务。

服务商的模型名、价格和接口会变化，应以其当前官方控制台为准。

最小配置示例：

```
LLM_BASE_URL=https://api.deepseek.com/v1
LLM_API_KEY=在服务商控制台创建的Key
```

```
LLM_MODEL=服务商当前支持的模型名
LLM_EXTRA_JSON={"thinking":{"type":"disabled"}}
```

阿里云百炼示例：

```
LLM_BASE_URL=https://dashscope.aliyuncs.com/compatible-mode/v1
LLM_API_KEY=在百炼控制台创建的Key
LLM_MODEL=服务商当前支持的模型名
LLM_EXTRA_JSON={"enable_thinking":false}
```

平台可以给不同步骤分配不同模型：

| 变量 | 任务 |
| --- | --- |
| `PREFILTER_MODEL` | 公益相关性预筛 |
| `SCORE_MODEL` | 重要性评分 |
| `UNDERSTAND_MODEL` | 内容理解 |
| `SUMMARIZE_MODEL` | 标题和摘要 |
| `STRUCTURE_MODEL` | 结构化抽取 |
| `GROUP_MODEL` / `GROUP_REVIEW_MODEL` | 事件归组和复核 |
| `DIGEST_MODEL` | 事件摘要 |
| `REPORT_MODEL` | 周报和月报 |
| `TRANSLATE_MODEL` | 翻译 |

不设置这些变量时全部使用 `LLM_MODEL`。对非技术维护者，先维持一套稳定默认模型最容易维护。

费用异常时可以把 `MODEL_CALLS_ENABLED=false` 作为紧急止损。`COLLECT_ENABLED=false` 会停止采集。恢复前先查明原因，以免积压内容一次性触发大量付费请求。

## 五、信息源结构与新增来源

| 类型 | 当前例子 | 采集方式 | 常见问题 |
| --- | --- | --- | --- |
| RSS/Atom | 媒体、机构更新 | worker 定时读取 | feed 停更、日期不规范 |
| 网站列表 | 政府部门、机构官网 | 列表页与详情页解析 | 网站改版、验证码、403 |
| 微信公众号 | 公益时报、机构公众号 | WeRSS 和微信读书兼容层 | 登录失效、微信频控 |
| 邮件简报 | AmCham、慈善纪事简报 | QQ IMAP 发件人白名单 | 授权码失效、模板变化 |
| 外部推送 | 受控采集脚本 | `POST /api/ingest/items` | token 泄露、错误数据 |

运行时真值是 PostgreSQL 的 `sources.config`。`industry/sources.json` 只是初始 seed，不会覆盖数据库已有配置。

增加 RSS 或网站来源时：

1. 在后台「候选信源」或「新增信源」粘贴地址。
2. 让系统发现 feed，并预览数条真实内容。
3. 核对标题、原文发布日期和原文链接。
4. 使用唯一、稳定的英文 ID。
5. 初始暂停或隔离，检查后再启用为编辑候选。
6. 保持 `site_fulltext=false`，除非来源明确允许转载全文。

“候选信源”包含 NewsMail、charity-intelligence 等项目留下的历史线索，不等于全部可以一键启用。有些地址失效、有些已被当前来源覆盖、有些会返回验证码或 403。

### 微信公众号

WeRSS 在服务器运行，管理端只监听 `127.0.0.1:18001`。重新扫码或管理账号时，从本机建立 SSH 隧道：

```
ssh -N -L 18001:127.0.0.1:18001 <服务器用户>@<服务器地址>
```

然后打开 http://127.0.0.1:18001，使用 `/opt/werss/.env` 中的管理账号登录。验收必须同时确认：扫码成功、账号已添加、feed 有真实条目、Yi-Hot 能预览和入库、日期及原文链接正确。详见 `docs/WERSS_DEPLOY.md`。

### 邮件来源

当前白名单包含：

- `AmCham China Events <amchamevent@amchamchina.org>` 及其代发信封域，只保留公益、社会影响、ESG、可持续发展等相关活动；
- 爱德传一基金会《慈善纪事简报》`aidechuany@batch.lingxi360.com`。

采集器每 30 分钟用 IMAP `BODY.PEEK[]` 只读检查 QQ 邮箱，不标记已读、不移动、不删除。增加来源时应先登记发件地址和来源名称，再用历史样本试跑；不能吸收整个邮箱。

可信的邮件 `Date` 头作为发布日期；缺失或时区不可靠时显示“收录”，不会猜日期。详见 `docs/EMAIL_SOURCE_DEPLOY.md`。

## 六、分类、主题和标签

一条动态可以同时有三种维度：

| 维度 | 回答的问题 | 示例 |
| --- | --- | --- |
| 内容形态 `category` | 这是什么形式? | 政策、机构、项目、研究、一线、观点 |
| 公益领域 `topic` | 它关注什么议题? | 儿童教育、儿童保护、环境保护 |

| 维度 | 回答的问题 | 示例 |
| --- | --- | --- |
| 卡片标签 `tag` | 给读者看的短提示 | 儿童教育、政策、教育部 |

因此“教师法修订”可以同时是内容形态“政策”和公益领域“儿童教育”。“政策倡导”是一个使命主题，指倡导行动，不等于全部政策新闻。

当前 13 个公益领域是：儿童教育、营养健康、性别平等、儿童保护、网络保护、青年发展、亲子养育、残障融合、应急救援、环境保护、募集筹款、政策倡导、其他领域。前 12 项允许交叉；“其他领域”只用于未命中前 12 项的公益内容，不能与具体领域同时出现。

内容进入公开动态至少需要：来源参与方式为 `editorial`、公益相关性通过、有标题、有摘要。独立“精选”栏目暂时隐藏，但精选状态仍保留，用于数据分析和未来恢复。

## 七、日期和重复内容

| 字段 | 含义 |
| --- | --- |
| `published_at` / `publishedAt` | 原文真正发布的时间 |
| `discovered_at` / `discoveredAt` | Yi-Hot 第一次抓到它的时间 |

动态页优先显示和使用原文发布日期；原文确实没有日期时才显示“收录”。晚到旧内容通过 `backfill` 回到原文日期位置，不能用今天的收录时间冒充新内容。

日期异常时依次检查原始页面或邮件、`published_at`、`discovered_at`、`backfill`、`timeline_at` 和发布物化记录。不要直接修改 `publications.sort_at`，下一次发布会覆盖它。

去重分为规范 URL、邮件 Message-ID、文章身份、规范化标题、同一事实事件和总报引用等层次。发现重复时先判断是同一篇、同一事实还是标题相似的不同事件，再合并；不要只按标题批量删除。

## 八、公益总报和邮件订阅

- 日报已经停用。
- 周报按完整自然周生成，月报按完整自然月生成。
- 报告按原文发布日期纳入周期内全部合格候选，不只取少量精选。
- 没有合格内容的周期不生成空报告。
- 历史重组脚本是 `scripts/recompose-period-history.ts`，`--through` 是不包含的截止日。

公开订阅流程：

```
/subscribe 提交邮箱
        ↓
发送 48 小时有效的确认邮件
        ↓
读者点击确认
        ↓
```

```
从下一期开始接收周报/月报
          ↓
邮件中的签名链接可以退订
```

每个收件人单独发送，数据库 outbox 按“报告类型 + 期号 + 订阅人”防重。明确永久退信会标记为 `bounced`；SMTP 已接受但回执中断时记录 `unknown`，避免自动重发造成重复邮件。

检查命令：

```
systemctl status yihot-email-delivery.timer
journalctl -u yihot-email-delivery.service -n 50 --no-pager
```

当前每 30 分钟领取最多 20 封，理论队列吞吐约 40 封/小时，现阶段建议控制在 100–200 个订阅者。扩大推广前应复用 SMTP 连接、连续处理队列并限速；超过数百至上千订阅者时改用专业邮件服务。详见 `docs/EMAIL_DELIVERY.md`。

## 九、公开 API、RSS 和 MCP

API 是给程序读取数据的地址，普通读者不需要使用。公开读取不需要后台密码或 API Key。

浏览器示例：

https://49.233.72.222/yihot/api/v1/items?mode=all&window=7d&by=published&limit=10

命令行：

```
curl "https://49.233.72.222/yihot/api/v1/items?mode=all&window=7d&by=published&limit=10"
```

JavaScript：

```
const response = await fetch(
  "https://49.233.72.222/yihot/api/v1/items?mode=all&window=7d&by=published&limit=10",
);
if (!response.ok) throw new Error(`Yi-Hot API ${response.status}`);
const data = await response.json();
console.log(data.items);
```

常用参数：

| 参数 | 可选值 | 作用 |
| --- | --- | --- |
| `mode` | `all`、`selected` | 全部合格动态或精选状态动态 |
| `window` | `24h`、`7d` | 时间窗口 |
| `by` | `published`、`timeline` | 原文发布日期或平台时间线 |
| `category` | API 内容形态 key | 按内容形态过滤 |
| `q` | 2–200 字符 | 搜索 |

| 参数 | 可选值 | 作用 |
| --- | --- | --- |
| `limit` | 1–100 | 每页条数 |
| `cursor` | 上一页返回值 | 翻页 |

长期集成应使用 `/api/v1`，不要依赖后台 API 或网页内部 `/api/site/*`。RSS 和 MCP 与网页共用统一公开读取层，不会因为读者打开而调用模型。

`POST /api/ingest/items` 是受保护的写入入口，需要至少 16 位的 `INGEST_TOKEN`。它不是公共 API，token 不能放入网页、客户端应用或公开仓库。

# 十、服务器容量基线

生产服务器是腾讯云北京区域 2 核、2GB 内存、50GB 磁盘。2026-10-18 实测：

- 磁盘使用约 63%，剩余约 18GB；
- PostgreSQL 约 90MB，最大连接 100，当前约使用 15；
- 主机已使用少量 Swap，内存是第一瓶颈；
- 主要容器没有重启记录。

短时只读探测：

| 服务 | 实测 | 当前保守规划 |
| --- | --- | --- |
| Yi-Hot 动态页 | 20 并发全部成功，P95 约 0.58 秒 | 20–30 名同时活跃读者 |
| Yi-Hot 邮件 | 20 封/30 分钟 | 100–200 个订阅者 |

访问分散时，Yi-Hot 约可承载 1,000–3,000 次日访问。这不是保证值；页面类型、缓存、机器人、WeRSS 刷新和批处理都会改变容量。

出现以下情况应优化或扩容：可用内存持续低于 300MB、Swap 持续增长到 1GB 以上、负载均值长期超过约 1.5、页面 P95 长期超过 1 秒、出现 5xx、磁盘超过 80%或邮件接近 200 订阅者。下一档优先考虑 2核4GB。

## 当前成本概览

成本分成固定基础设施、Yi-Hot 模型调用和可选服务三部分。下面是 **2026-10-18 的规划快照**，用于交接和做预算，不代替腾讯云及模型服务商账单。

| 项目 | 当前估算 | 计费特点 |
| --- | --- | --- |
| 腾讯云 2核2GB 主机 | **实际购买价 ¥99/年，折合 ¥8.25/月** | 当前项目真实成本；续费前查看控制台新价格 |
| Yi-Hot 模型 API | 约 ¥35–63/月 | 依据生产真实 token 和当前后台高峰单价推算 |
| WeRSS 软件 | ¥0 软件订阅费 | 自托管开源软件，但占用服务器 CPU、内存和磁盘 |
| QQ 邮件收取和发送 | 当前无单独 API 费 | 使用已有 QQ 邮箱；受个人邮箱发送限制和风控约束 |

| 项目 | 当前估算 | 计费特点 |
| --- | --- | --- |
| GitHub 私有仓库 | 当前可为 ¥0 | 取决于 GitHub 账号方案和 Actions 用量 |
| HTTPS | 当前没有单独证书费 | 若使用域名可申请 ACME 免费证书；域名另计 |
| 异地备份 | 尚未形成已核实固定账单 | 建议另留 ¥1–20/月，取决于保留周期、容量和下载流量 |

不含域名和可选备份时，现阶段可以先按：

```
每月：约 ¥43–72
每年：约 ¥519–855
```

准备项目预算时建议再留 20%–30% 余量，用于历史回灌、模型调价、失败重试、临时扩容和备份下载。

当前服务器是优惠购买的 **¥99/年**，这是本项目预算应使用的真实金额。腾讯云官网当前展示的中国内地同级轻量入门套餐为 2核2GB、50GB SSD、4Mbps、300GB 月流量，约 ¥50/月、¥510/年；这个刊例只用于判断未来续费或重购风险，不是当前账单。维护者应在到期前打开腾讯云轻量应用服务器官方页面和实例续费页核对。

## Yi-Hot 模型费用怎样算出来

生产数据库在 2026-09-30 至 2026-10-18 记录：

| 指标 | 数量 |
| --- | --- |
| 线上模型调用 | 3,806 次 |
| 输入 token | 9,329,413 |
| 输出 token | 253,384 |
| 有调用的自然日 | 16 天 |
| 失败回执 | 7 次 |

后台当前为 `llm / deepseek-chat` 维护的高峰估算单价是：

```
输入：$0.30 / 100 万 token
缓存输入：$0.006 / 100 万 token
输出：$1.20 / 100 万 token
```

当前回执没有可靠区分缓存命中 token，因此保守计算把全部输入按普通输入价计算：

```
输入费用 = 9.329413 × $0.30 = $2.7988
输出费用 = 0.253384 × $1.20 = $0.3041
合计约 $3.10
```

按规划汇率 `1 USD ≈ ¥7.2`，约为 **¥22.3**。这段时间包含初始化和历史回填，并不是一个完整平稳月份：

- 按 19 个日历日平均外推 30 天，约 **$4.90 / ¥35**；

- 按最近 7 天的高负载外推 30 天，约 **$8.73 / ¥63**；
- 最近 7 天包含历史报告重建、分类回填等尖峰，因此把 **¥35–63/月**作为当前规划区间比单点数字更合理。

以上按高峰单价估算，实际请求如果落在服务商优惠时段可能更低；服务商调价则可能更高。DeepSeek 当前模型与价格应从官方模型定价页重新核对。

## 当前模型名称需要复核

生产运行时和历史回执仍使用 `deepseek-chat`，后台也按这个名称匹配价格。DeepSeek 当前官方文档已经展示 `deepseek-flash` 和 V4 系列，并说明旧模型名存在退役或兼容映射变化。

这不会自动证明当前调用失败——生产近期仍有成功回执——但维护者应完成以下工作：

1. 在 DeepSeek 控制台确认 `deepseek-chat` 当前实际映射和账单单价；
2. 用少量 Yi-Hot 样本测试官方当前模型名的 JSON 稳定性；
3. 更新 `.env` 或后台模型选择；
4. 在「用量与成本」为新模型名新增精确价格；
5. 保留旧价格记录用于解释历史估算；
6. 观察成功率、p95 延迟、标题摘要质量和费用后再全面切换。

如果只改 `LLM_MODEL` 而不更新 `service_prices`，后台新调用会显示“未定价”，月化估算会失真。

## 单条内容和新信源的大致成本

用上述 3,806 次调用和当前 519 条公开记录做非常粗略的历史混合平均：

```
约 7.3 次模型调用 / 条公开内容
约 $0.006 / 条，约 ¥0.04 / 条
```

这个平均包含不同处理阶段、失败、事件归组和历史重算，不是严格边际价格，但适合做初步预算。例如新来源一次回灌 100 条，在当前模型和处理结构下可先预留约 **¥4–10**；如果文章很长、反复重跑、生成翻译或重建事件，费用会更高。

新增来源的成本不只取决于来源数量，更取决于：

- 首次回灌多少历史条目；
- 每天新增多少文章；
- 文章正文长度；
- 是否需要翻译、视觉、付费正文抓取；
- 是否触发大量事件归组和重算；
- 失败后是否反复人工重跑。

因此接入新来源时应先预览，再用 10–30 条样本首抓，观察后台用量后才决定是否扩大历史窗口。

### 周报、订阅人数和模型成本的关系

周报或月报是**每一期生成一次**，然后同一成品发送给所有订阅者。订阅者从 10 人增加到 100 人，不会让报告模型调用增加 10 倍；增加的是 SMTP 发送次数和邮件队列时间。

当前每封邮件没有单独 API 单价，但每个收件人会建立一次 SMTP 连接。订阅量扩大后的主要问题是 QQ 邮箱限流、风控、投递率和发送时间，而不是模型 token。转专业邮件服务后通常会按联系人数量或发送封数收费，应在迁移时单独询价。

### 扩容后的基础设施预算

按腾讯云当前官网同类套餐做规划参考：

| 规格 | 官网示例价格 | 适用情况 |
| --- | --- | --- |
| 当前 2核2GB、50GB | **实际 ¥99/年** | 当前规模，但内存余量有限；先用到续费或达到资源触发线 |
| 新购同级 2核2GB、50GB | 官网约 ¥50/月，¥510/年 | 当前优惠到期后的保守重购参考 |
| 2核4GB、100GB | 约 ¥100/月，¥1,020/年 | Yi-Hot 和 WeRSS 继续同机运行时更稳妥 |
| 4核8GB、180GB | 约 ¥245/月，¥2,499/年 | 明显增加访问、并发 AI 或更多自托管服务 |

这是产品页刊例，不含促销，也不代表当前实例必须立即升级。实际触发线仍以本章的内存、Swap、负载、P95、磁盘和错误率为准。

### 每月成本核对清单

- [ ] 腾讯云实例续费价、流量包和超额流量；
- [ ] Yi-Hot 后台近 30 天 token、调用、未定价模型和失败重试；
- [ ] DeepSeek/其他模型服务商实际扣费；
- [ ] QQ 邮箱是否触发限制，是否需要专业邮件服务；
- [ ] COS/对象存储备份容量和下载流量；
- [ ] 域名续费和证书状态；
- [ ] 本月是否有历史回灌、批量重算或压力测试等一次性支出；
- [ ] README 中的价格快照是否超过三个月未更新。

## 十一、巡检和故障处理

### 巡检表

| 频率 | 检查内容 | 正常表现 |
| --- | --- | --- |
| 每周 | 首页、动态、主题、总报 | 最近几天有内容，日期和链接合理 |
| 每周 | 后台运行与信源 | worker 持续运行，无成片失败 |

| 频率 | 检查内容 | 正常表现 |
| --- | --- | --- |
| 每周 | AmCham 和慈善纪事邮件 | IMAP 游标前移，发布日期正确 |
| 每月 | 用量与成本 | 调用和费用没有突然跳升 |
| 每月 | 磁盘、内存、容器 | 磁盘低于 80%，无重启循环 |
| 每季度 | 恢复演练和账号权限 | 凭据可解密，关键账号可登录 |

## 网站打不开

```
cd /opt/yihot
sudo docker compose <服务器现行的完整生产覆盖参数> ps
sudo docker compose <服务器现行的完整生产覆盖参数> logs --tail=100 web api
curl -fsS http://127.0.0.1/yihot/api/health
```

先看容器和健康接口，不要通过删除 volume 或数据库来尝试修复普通启动问题。

## 网站能开但没有新内容

1. 后台「信源」最近是否抓到内容；
2. 后台「运行」中的 worker 是否持续运行；
3. 新内容是否被公益相关性预筛拦截；
4. 原文发布日期是否较早，因 backfill 排在历史位置；
5. `COLLECT_ENABLED`、`MODEL_CALLS_ENABLED` 是否开启；
6. 模型账户余额和 API Key 是否正常。

不要用收录时间冒充发布日期来制造更新。

## WeRSS 故障

```
cd /opt/werss
sudo docker compose -f compose.yml -f compose.weread.yml ps
sudo docker compose -f compose.yml -f compose.weread.yml logs --tail=80
systemctl status yihot-weread.timer
journalctl -u yihot-weread.service -n 80 --no-pager
```

微信返回频控时不要反复刷新；登录失效时通过 SSH 隧道重新扫码。

## 邮件故障

```
systemctl status yihot-email-source.timer
journalctl -u yihot-email-source.service -n 50 --no-pager
systemctl status yihot-email-delivery.timer
journalctl -u yihot-email-delivery.service -n 50 --no-pager
```

QQ 邮箱使用 IMAP/SMTP 授权码，不是 QQ 登录密码。授权码失效时到邮箱设置重新生成，更新对应服务器 `.env` 后重启服务。

# 十二、本地开发、测试、同步和部署

## 环境要求与本机启动

- Node.js 24.11 或更高；
- npm workspaces；
- Docker 与 Docker Compose；
- 后端测试需要独立 PostgreSQL 测试库；
- Python 3 用于运维和邮件脚本。

```
npm ci
cp .env.example .env
node scripts/init-env.ts
docker compose up -d --build
```

本机通常访问 http://localhost:3000，后台是 http://localhost:3000/admin。`.env` 不能提交。

改动后的最低验证：

```
npm run typecheck
npm run build -w @aihot/web
node --test apps/web/tests/*.test.ts
```

涉及数据库行为时，`DATABASE_URL` 必须指向名称以 `_test` 或 `_ci` 结尾的空测试库，然后运行迁移和 `npm test`。涉及信源清单时还要运行：

```
npm run sources:audit
npm run sources:audit:check
```

## 同步 GitHub

当前开发机的 Git smart HTTP 不稳定，推送必须走仓库脚本：

```
python tools/compare.py
python tools/sync.py -m "说明改了什么以及为什么" README.md
python tools/compare.py
```

远端删除使用 `tools/delete.py`。详情见 `tools/README.md`。

## 部署腾讯云

生产代码目录是 `/opt/yihot`。上传本次完整文件集合后运行：

```
cd /opt/yihot
sudo docker compose <服务器现行的完整生产覆盖参数> config --quiet
sudo docker compose <服务器现行的完整生产覆盖参数> build
sudo docker compose <服务器现行的完整生产覆盖参数> up -d
```

`industry/`、`data/` 和源码会被烘焙进镜像，变化后必须 rebuild。禁止把 `docker cp` 加 `restart` 当成正式部署；容器重建后临时文件会消失，`.env` 也不会在普通 restart 时重新读取。

生产至少验收：门户、`/yihot/`、`/yihot/all`、`/yihot/topics`、`/yihot/subscribe` 和 `/yihot/api/health` 返回正常；Yi-Hot 后台匿名访问应跳转登录页。

最后用 Git blob SHA 核对本地、GitHub `main` 和服务器 `/opt/yihot`，不要用 commit SHA 判断三方一致。

## 十三、备份、换电脑和交接

| 内容 | 位置 | 用途 |
| --- | --- | --- |
| 源码与文档 | GitHub 私有仓库 | 恢复应用和运维知识 |
| PostgreSQL | Docker `db` volume / 对象存储 | 文章、分析、总报、订阅、审计 |
| 主配置 | `/opt/yihot/.env` | 密码、模型和签名 |
| WeRSS | `/opt/werss/data` 与 `.env` | 公众号订阅和登录状态 |
| 邮件状态 | 两个邮件服务的状态目录 | IMAP 游标和退信游标 |
| 加密凭据 | `secrets/credentials.env.enc` | 新设备恢复核心凭据 |

加密凭据不能替代数据库和 WeRSS 数据备份。每季度至少验证一次能解密归档、能登录关键账号，并确认数据库备份可恢复。

新设备：

```
git clone https://github.com/CochraneK/Yi-hot
cd Yi-hot
bash tools/secrets.sh decrypt
npm ci
python tools/compare.py
```

之后按顺序读：`AGENTS.md`、本文、`docs/PROJECT_CONTEXT.md`、最新 `docs/HANDOFF-*.md`、`docs/memory/MEMORY.md`、`tools/README.md`、`secrets/README.md`。

交给不懂 AI 的维护者时，他只需要掌握四件事：每周查看网站和后台；异常时保存时间、地址和错误；密钥只放密码管理器与服务器配置；技术修改交给开发人员或编码 Agent，并要求完成测试、同步、部署和验收。

可以把下面这段原样交给技术人员或编码 Agent：

```
请先阅读仓库根目录 AGENTS.md、README.md、docs/PROJECT_CONTEXT.md、
最新的 docs/HANDOFF-*.md、docs/memory/MEMORY.md、tools/README.md 和
```

```
secrets/README.md。先核实线上现象和运行状态，再修改、测试、同步
GitHub 并部署腾讯云。不要输出或提交任何密钥；三方一致性用 Git blob SHA 核验。
```

## 十四、代码和行业配置地图

| 位置 | 作用 |
| --- | --- |
| `apps/web` | 页面、SSR 和反向代理 |
| `apps/api` | HTTP API、后台鉴权、订阅和 ingest |
| `apps/worker` | 后台任务进程 |
| `packages/backend` | 采集、模型、发布、数据库和业务逻辑 |
| `packages/contracts` | 前后端共享类型和 HTTP 契约 |
| `industry/site.ts` | 站名与公开文案 |
| `industry/taxonomy.ts` | 内容形态和分类 |
| `industry/topics.json` | 主题与机构板块 |
| `industry/sources.json` | 初始信源 seed |
| `industry/prompts/` | 相关性、摘要、评分和报告提示词 |
| `industry/selection.ts` | 评分与入选门槛 |
| `industry/card-tags.ts` | 卡片短标签归一化 |
| `industry/brand/` | Logo、图标和品牌资源 |
| `database/migrations` | 向后兼容的数据库迁移 |
| `deploy/` | Caddy、WeRSS 和邮件服务部署材料 |

站名、关注来源、重要性判断、分类、隐私条款和服务条款必须由项目负责人决定。评分门槛要用标注样本校准，不要由开发者凭感觉修改。

主题和信源 seed 都是 upsert/只增逻辑：从 JSON 删除不代表数据库记录自动消失。正式下线需要明确的数据库处理和验证。

## 十五、后台所有设置逐项说明

后台左侧分为“内容”和“系统”两组。手机端显示为顶部横向导航。右上角或导航数字表示有待处理项目，不代表服务一定故障。

## 内容诊断

可搜索文章并进入完整处理链。常用操作：

| 操作 | 适用情况 | 影响 |
| --- | --- | --- |
| 修改公开字段 | 标题、摘要或日期已有可靠证据证明错误 | 保存人工覆盖，后续发布沿用 |
| 隐藏/恢复 | 内容不适合公开、原文撤回或已核实可恢复 | 改变公开可见性，保留数据和审计 |
| 重新处理 | 原始正文已修复，或旧模型结果明显错误 | 新增模型调用，只影响后续结果 |
| 拆离事件 | 两条内容被错误归为同一事实 | 重建事件关系，不删除文章 |
| 合并事件 | 多个事件实际描述同一事实 | 统一展示和总报引用 |
| SEO 开关 | 页面不适合搜索引擎收录 | 影响索引，不等于隐藏页面 |

任何人工修改都要填写具体理由和证据。日期修正应写原文日期来源，不能只写“看起来不对”。

## 信源列表和信源详情

信源详情中的字段：

| 字段 | 含义 | 建议 |
| --- | --- | --- |
| 名称 | 后台和来源署名使用的名称 | 使用机构或栏目的正式简称 |
| 采集间隔 | 两次轮询的最短分钟数 | 普通来源 30–120 分钟；不要无意义地设为 1 |
| 参与方式 | `editorial` 可成为动态；`ambient` 只作讨论证据；隔离不进入正常发布 | 新来源先隔离或暂停 |
| 等级 | 来源在现有判断体系中的层级 | 按来源性质选择，不按喜好抬高 |
| 讨论分组 ID | 同一机构多个账号共用，避免热点重复计数 | 同主体多入口时设置同一值 |
| 运营主体 ID | 关联机构实体和机构主题 | 使用已有稳定实体 ID |
| 标签 | 来源固有提示 | 只放稳定属性，不替代文章级分析 |
| 一手信源 | 官方账号或官网的来源属性 | 只在能确认官方主体时开启 |
| 站内全文 | 网页是否能展示完整原文 | 默认关闭，明确获授权才开启 |
| 对外全文 | RSS/API 是否能输出完整原文 | 比站内全文更谨慎，默认关闭 |
| 采集配置 JSON | 抓取器地址、选择器、路径等 | 保存前必须预览 |

“预览抓取”不会入库，适合验证配置。“立即采集”会进入正式队列，可能触发分析和费用。暂停会保留已有内容和历史；恢复后会立即排队采集。

详情页还显示健康状态、连续失败次数、游标、上次和下次采集、最近条目、采集记录和人工修改记录。发现“可能漏采”或长期“续读”时，应检查分页和单轮上限。

## 反馈

可以按状态和关键词查找反馈，处理更正、下架或滥用。擦除反馈内容和封禁来源属于高影响操作，必须填写原因。封禁针对匿名来源哈希，不应被当作用户身份系统。

## 运行

这里汇总任务、模型回执和投递。常见人工操作：

- 对失败文章重新排队；
- 对结果未知的付费调用确认是否已经计费；
- 对结果未知的外部投递确认实际结果。

“结果未知”表示网络在请求发出后中断，不能简单重试，否则可能重复付费或重复发送。先查服务商记录或收件结果。

## 用量与成本

时间范围可用于观察短期异常和长期趋势。单价表中的服务名与模型名必须和真实回执匹配。

| 单价字段 | 单位 | 说明 |
| --- | --- | --- |
| 输入 | 每百万输入 token | 模型读取内容的费用 |
| 缓存输入 | 每百万缓存命中 token | 当前调用记录不能可靠区分时只作留档 |
| 输出 | 每百万输出 token | 模型生成内容的费用 |
| 按次 | 每次请求 | 抓取或按请求计费的服务 |

精确模型价格优先于服务兜底价格。删除精确价格后才会回退到空模型名的服务价格。价格变化时填写生效依据和日期。

## 模型与评测

模型来源优先级是：**后台切换 > 环境变量 > 代码默认**。后台选择“恢复默认”只会删除后台覆盖，随后回到环境变量或代码默认。

切换只影响新任务，不会重算历史内容。视觉任务只能选择标记为支持视觉的模型。页面中的成功率、p50/p95 延迟、token 和费用应结合看；不要仅凭一次主观回答切换生产模型。

SelectBench 用同一批标注样本比较模型，适合在更换精选/评分模型前使用。导入评测结果本身不切换生产模型。

### 设置：关于页二维码

可替换微信公众号和飞书群二维码，无需发布代码。支持 PNG、JPG、WebP，最大 2MB，宽高至少 120 像素。上传后写入持久化数据目录并记录审计，关于页缓存最多约 5 分钟后更新。

替换前先用另一部手机扫码验证；不要上传个人收款码或包含无关隐私的截图。

### 设置：通知目的地

这里控制已经登记的飞书等推送目标是否接收新内容。启用时会记录 `enabled_at`，启用之前的历史内容不会补推；停用后只停止新推送，不删除已有投递记录。

页面开关只有在服务器相应环境变量和 webhook/应用凭据也配置正确时才会真正发送。开发和彩排环境即使显示启用，也可能被全局安全阀阻止。

### 设置：付费请求上限

每个服务有每分钟、每小时、每天三层调用次数限制。实际调用必须同时低于三层上限。

- 任意一层填 `0` 会立即停用该服务。
- 达到上限后请求暂停，等待相应窗口释放，不会绕过熔断。
- 页面“已用”显示近 1 小时和近 24 小时的线上调用次数。
- 这些是**调用次数上限**，不是人民币金额；仍需在服务商控制台设置金额预算。
- 调高之前先根据近期用量和单价估算最坏成本，调低时考虑是否会让内容处理长期积压。

### 审计记录

后台模型、预算、信源、通知、二维码、内容和反馈等写操作都会记录操作人、时间、前后值与原因。它是排查“谁改了什么”的第一入口。

## 十六、增加信息源的完整操作手册

### 先判断应该使用哪种来源类型

```
有 RSS/Atom？ ── 是 → rss
     │
    否
     ↓
公开网页有稳定文章列表？ ── 是 → web_list
     │
    否
     ↓
有公开 JSON API？ ── 是 → json_list
     │
    否
     ↓
微信公众号？  → WeRSS 的 rss
邮件简报？    → email-source 发件人白名单
```

```
外部系统主动推送？ → external + 受保护 ingest API
X 账号搜索？ → x_search（需要 SocialData 和预算）
```

优先使用官方 RSS，其次公开 JSON API，再次是网页列表。能不用浏览器渲染和付费抓取就不用，因为结构越简单越稳定。

## RSS 示例

```
{
  "feedUrl": "https://example.org/feed.xml"
}
```

创建前确认 feed 能直接返回 XML，条目链接指向原文，日期带时区。不要把聚合站 RSS 冒充机构官方来源。

## 网站列表示例

```
{
  "url": "https://example.org/news",
  "baseUrl": "https://example.org",
  "itemSelector": "article",
  "linkSelector": "a",
  "titleSelector": "h2",
  "allowUrlPrefixes": ["https://example.org/news/"]
}
```

`allowUrlPrefixes` 用于限制只能采集目标栏目，避免导航、招聘、登录和外站链接混入。选择器应在多页样本上验证。网页一旦改版，CSS 选择器可能失效。

## JSON API 示例

```
{
  "url": "https://example.org/api/posts",
  "mode": "json_api",
  "method": "GET",
  "itemsPath": "data.items",
  "titlePaths": ["title"],
  "summaryPaths": ["summary"],
  "urlTemplate": "{raw:url}"
}
```

只接入公开、稳定、允许使用的接口。不要把登录 Cookie、Bearer Token 或个人账号凭据直接写入信源 JSON；需要鉴权的来源应由后端凭据机制单独支持。

## 公众号来源

1. 建立 WeRSS SSH 隧道并登录。
2. 搜索并核实公众号认证主体。
3. 添加账号，等待真实文章进入 feed。
4. 复制单账号 RSS 地址。

5. 在 Yi-Hot 后台以 RSS 创建，先暂停。
6. 预览日期、标题、原文短链和摘要。
7. 立即采集少量样本，核对公开结果后启用。

不要复制 WeRSS 后台 API 地址。微信会话失效时重新扫码，不需要重建 Yi-Hot 来源。

## 邮件来源

邮件来源不在通用后台表单里直接填邮箱密码。技术维护者需要：

1. 在 `deploy/email-source/collect.py` 的允许发件人配置中登记来源 ID 和地址；
2. 对代发平台同时核对显示发件人和信封域；
3. 准备数封真实历史样本，验证正文、链接、日期和退订链接过滤；
4. 增加或更新数据库来源记录；
5. 运行邮件采集单元测试；
6. 部署脚本和配置，手动试跑；
7. 观察定时器至少一个周期。

不要因为一封转发邮件就放宽整个域名。历史回灌使用 `MAIL_BACKFILL_AFTER` 一次性执行，完成后恢复普通增量模式。

## 新来源验收清单

- [ ] 来源主体和版权边界清楚；
- [ ] 至少预览 5 条不同日期的内容；
- [ ] 标题、链接、发布日期正确；
- [ ] 没有混入导航、招聘、营销和重复列表；
- [ ] 原文缺日期时明确显示“收录”，没有伪造日期；
- [ ] `site_fulltext`、`syndicate_fulltext` 默认关闭；
- [ ] 新来源先隔离或暂停；
- [ ] 正式采集后的相关性、分类和去重正确；
- [ ] 运行一个完整轮询周期后没有连续失败；
- [ ] 若改 `industry/sources.json`，已重生成信源审计快照并更新测试基线。

## 修改和停用已有来源

网站改版时先复制现有 JSON 到本地留档，再修改并预览。使用详情页的版本保护保存，避免覆盖另一位维护者刚做的改动。

来源永久停止时优先“暂停”，保留历史和审计。只有法律、隐私或数据治理明确要求删除时才设计专项清理；不能通过删来源顺便删历史文章。

## 当前生产信源台账

以下是 2026-10-19 核查并扩充后的生产运行时清单，不是 `industry/sources.json` 的初始样例。当前共 **31 个来源：30 个启用，1 个暂停**，全部使用 `editorial` 参与方式。

### 网站列表 `web_list`：21 个，全部启用

| ID | 显示名称 | 等级 | 地址 |
| --- | --- | --- | --- |
| `web-mca-civil-news` | 民政部 · 民政要闻 | T1 | `https://www.mca.gov.cn/n152/n164/index.html` |
| `web-mca-notice` | 民政部 · 通知公告 | T1 | `https://www.mca.gov.cn/n152/n165/index.html` |
| `web-mca-business` | 民政部 · 业务动态 | T1 | `https://www.mca.gov.cn/n152/n167/index.html` |
| `web-mca-local` | 民政部 · 地方动态 | T1.5 | `https://www.mca.gov.cn/n152/n168/index.html` |
| `web-moe-news` | 教育部 · 工作动态 | T1 | `http://www.moe.gov.cn/jyb_xwfb/gzdt_gzdt/` |
| `web-court-spc-news` | 最高人民法院 · 新闻 | T1 | `http://www.court.gov.cn/zixun/gengduo/24.html` |
| `web-mee-hjyw` | 生态环境部 · 环保要闻 | T1 | `http://www.mee.gov.cn/ywdt/hjywnews/` |
| `web-mee-xwfb` | 生态环境部 · 新闻发布 | T1 | `http://www.mee.gov.cn/ywdt/xwfb/` |
| `web-mee-zcwj` | 生态环境部 · 政策文件 | T1 | `http://www.mee.gov.cn/zcwj/` |
| `web-cca-federation-news` | 中国慈善联合会 · 联合会动态 | T1 | `https://charityalliance.org.cn/dl/771e1p1pcD.html` |
| `web-nandu-org-news` | 南都公益基金会 · 机构动态 | T1 | `https://www.naradafoundation.org/category/32` |
| `web-savethechildren-cn` | 救助儿童会中国 · 最新进展 | T1 | `http://www.savethechildren.org.cn/news_0` |
| `web-cctf-news` | 中国儿童少年基金会 · 动态 | T1 | `https://www.cctf.org.cn/news/` |
| `web-onefoundation-news` | 壹基金 · 最新活动 | T1 | `https://onefoundation.cn/news/` |
| `web-cfpa-news` | 中国乡村发展基金会 · 机构新闻 | T1 | `http://cfpa.org.cn/news/news.aspx` |
| `web-cwdf-news` | 中国妇女发展基金会 · 本会新闻 | T1.5 | `https://www.cwdf.org.cn/index.php?m=content&c=index&a=lists&catid=26` |

| ID | 显示名称 | 等级 | 地址 |
|---|---|---|---|
| web-cdpf-news | 中国残联·残联要闻 | T1 | https://www.cdpf.org.cn/xwzx/clyw2/index.htm |
| web-mem-emergency-news | 应急管理部·应急要闻 | T1 | https://www.mem.gov.cn/xw/yjyw/ |
| web-cac-policy | 中国网信网·政策法规 | T1 | https://www.cac.gov.cn/wxzw/zcfg/A093703index_1.htm |
| china-development-brief | 中国发展简报 | T2 | https://www.chinadevelopmentbrief.org.cn/ |
| gongyi-times | 公益时报·公益资讯 | T2 | http://www.gongyishibao.com/html/gongyizixun/list.html |

### RSS：6 个，其中 5 个启用

| ID | 显示名称 | 状态 | 地址/说明 |
|---|---|---|---|
| rss-oxfam | Oxfam 乐施会·新闻 | 启用 | https://www.oxfam.org/en/rss.xml |
| rss-givedirectly | GiveDirectly·动态 | 启用 | https://www.givedirectly.org/feed |
| ssir | Stanford Social Innovation Review | 启用 | https://ssir.org/site/rss_2.0 |
| wechat-gongyi-times | 公益时报（微信公众号） | 启用 | WeRSS MP_WXS_2395372392，读取最近 30 条 |
| wechat-amcham-china | 中国美国商会 AmCham China（微信公众号） | 启用 | WeRSS MP_WXS_2390109349，读取最近 80 条 |
| rss-un-news | 联合国新闻（中文） | 暂停 | 官方 feed 已登记，但当前不参与采集 |

公益时报同时有网页和公众号两个入口，AmCham 同时有公众号和邮件入口。它们是有意保留的独立入口，文章层会按规范 URL、标题和事件关系去重；不要因为入口重复就直接删除其中一个。

### JSON：2 个，全部启用

| ID | 显示名称 | 地址 |
|---|---|---|
| json-foundation-center-fti | 基金会中心网·动态 | https://api.foundationcenter.org.cn/api/HomeAPI/News |
| json-women-wq | 全国妇联·依法维权 | https://www.women.org.cn/5524//5528/NewsList_0.json |

### 邮件入口：2 个，全部启用

| ID | 显示名称 | 允许的主要发件地址 | 处理方式 |
| --- | --- | --- | --- |
| `email-amcham-events` | AmCham China Events 邮件 | `amchamevent@amchamchina.org`，同时核对代发域 | 只保留社会影响、公益、ESG、教育、儿童、残障、环境、社区、志愿等相关活动 |
| `email-amity-chuanyi` | 爱德传一基金・慈善纪事简报 | `aidechuany@batch.lingxi360.com` | 以整期简报接入，过滤退订和统计链接 |

邮件来源在数据库中是 `external`，实际拉取由 `/opt/yihot-email/collect.py` 和 systemd timer 完成。后台“立即采集”不能代替邮件定时器。

## 当前 WeRSS 公众号台账

以下为 2026-10-18 直接从服务器 `/opt/werss/data/we_mp_rss.db` 读取的账号：

| WeRSS ID | 公众号 | WeRSS 文章数 | 是否进入 Yi-Hot | 当前入口 |
| --- | --- | --- | --- | --- |
| `MP_WXS_2395372392` | 公益时报 | 43 | 是 | `wechat-gongyi-times` |
| `MP_WXS_2390109349` | 中国美国商会 AmCham China | 80 | 是 | `wechat-amcham-china` |
| `MP_WXS_3567681740` | 爱德传一基金 | 0 | 否 | 当前使用邮件《慈善纪事简报》 |

“出现在 WeRSS”与“已纳入 Yi-Hot”是两件事：WeRSS 里有账号，只表示已登记公众号；必须有文章、feed 可读，并在 Yi-Hot 建立启用的 RSS 来源后才算完成接入。

2026-10-19 曾因重建时只加载基础 Compose 和网页代理覆盖、漏掉 `compose.werss.yml`，导致 worker 解析不到 `werss`。恢复时必须同时加载 `docker-compose.yml`、`compose.futureme-proxy.yml` 和 `compose.werss.yml`；两处公众号随后手动采集成功，健康状态恢复为 `ok`。

## 新增微信公众号 RSS：逐步点击教程

下面按第一次操作的人完全不知道 WeRSS 来写。

### 第 1 步：连接 WeRSS 管理端

WeRSS 没有公开管理地址。打开 PowerShell、Windows Terminal 或 macOS/Linux 终端：

```
ssh -N -L 18001:127.0.0.1:18001 <服务器用户>@49.233.72.222
```

这个终端保持打开且没有输出是正常的。然后用浏览器打开：

```
http://127.0.0.1:18001
```

登录账号来自服务器 `/opt/werss/.env`。忘记密码时由有 SSH 权限的维护者读取或重置；不要把 WeRSS 管理端直接开放到公网。

如果本机 `18001` 被占用，可以改成本机其他端口，例如：

```
ssh -N -L 28001:127.0.0.1:18001 <服务器用户>@49.233.72.222
```

随后打开 `http://127.0.0.1:28001`。

#### 第 2 步：确认微信登录仍有效

在 WeRSS 管理页检查微信公众平台或微信读书登录状态。失效时点击相应登录入口，用具备权限的微信扫码并在手机确认。扫码二维码只用于这次服务器会话，不要截图发给他人。

如果出现 `200013: freq control`，停止反复刷新，等待一段时间后由定时任务重试。扫码成功不等于采集成功。

#### 第 3 步：搜索并添加公众号

1. 在 WeRSS 中搜索公众号全名。
2. 对照头像、微信号、认证主体和近期文章，避免添加同名仿冒账号。
3. 点击添加或订阅。
4. 等待异步采集完成；页面立即显示 `total=0` 时不要立刻判定失败。
5. 确认至少出现一篇真实文章，标题、发布日期和原文链接正确。

仅有搜索结果、没有 feed 文章时，还不能接入 Yi-Hot。

#### 第 4 步：复制单账号 RSS 地址

在该公众号详情中复制 RSS 链接。有效路径形如：

```
http://127.0.0.1:18001/feed/MP_WXS_1234567890.rss
```

端口和主机可能不同，但路径必须是单账号 `/feed/<ID>.rss`、`.xml` 或 `.atom`。不要复制后台页面、全局 API、文章管理地址或包含登录凭据的链接。

#### 第 5 步：在 Yi-Hot 后台创建

1. 打开 https://49.233.72.222/yihot/admin。
2. 进入「信源」。
3. 点击「候选信源」。
4. 在“补充建议”卡片底部点击「添加公众号 RSS（WeRSS）」。
5. 把刚复制的单账号 RSS 地址粘贴进“公众号 RSS 地址”。后台会把本机地址安全转换成容器内部的 `http://werss:8001/feed/...`。
6. 填写 ID：建议 `wechat-机构英文简称`，只能使用小写字母、数字和连字符，创建后不能改。
7. 名称写“机构正式名称（微信公众号）”。
8. 类型保持 `rss`。
9. 首次等级保持 T2，除非已有清楚的来源分级依据。
10. 参与方式保持 `isolated`，采集间隔保持 120 分钟。
11. 官方认证公众号可以勾选“一手信源”，同时记录认证主体证据。

12. 站内全文和对外全文都保持关闭。

配置最终应类似：

```
{
  "feedUrl": "http://werss:8001/feed/MP_WXS_1234567890.rss"
}
```

#### 第 6 步：先预览，后创建

点击“预览抓取”，至少检查 5 条：

- 标题不是菜单、乱码或摘要截断；
- 日期是原文发布日期，不是预览当天；
- 链接打开微信原文；
- 没有把同一篇文章重复多次；
- 内容确实来自目标公众号。

没有条目时不要创建一个会持续失败的来源。返回 WeRSS 检查账号是否真正采集到文章。

预览正确后点击“创建”。新来源默认暂停，这是保护措施。

#### 第 7 步：首抓和启用

1. 进入刚创建的信源详情。
2. 再点一次“预览抓取”。
3. 点击“恢复”启用；系统会立即排队一次采集。
4. 等待 worker 处理，检查“采集记录”和“最近条目”。
5. 进入一条内容诊断，核对正文素材、原文日期、摘要、标签和公开状态。
6. 确认范围合适后，把参与方式从 `isolated` 改为 `editorial` 并写明理由。
7. 初期保持 120 分钟；稳定运行后再根据更新频率调整，通常不低于 60 分钟。

#### 第 8 步：验收和记录

完成标准：WeRSS 有真实条目、RSS 可读、Yi-Hot 首抓成功、日期与链接正确、至少一条内容完成分析、没有全文版权越界。把公众号名称、认证主体、WeRSS ID、Yi-Hot source ID、接入日期和维护说明补入本节台账。

### 候选信源现在还有什么

后台候选库包含两层：

1. **补充建议 11 条**：经过本项目人工复核，状态比较明确；
2. **历史线索 200 条**：NewsMail 99 条加 charity-intelligence 101 条，只用于搜索发现，不代表有 200 个遗漏来源，也不代表获得采集许可。

当前 11 条补充建议：

| 状态 | 来源 | 当前结论 |
| --- | --- | --- |
| 已纳入 | AmCham China Events 邮件 | QQ IMAP 白名单入口已运行 |
| 已纳入 | 爱德传一・慈善纪事简报 | 邮件入口已运行 |
| 已纳入 | 中国发展简报 | 官网列表已运行 |
| 已纳入 | 公益时报・公益资讯 | 官网列表已运行 |
| 已纳入 | Stanford Social Innovation Review | RSS 已运行 |
| 已纳入 | 中国妇女发展基金会 | 本会新闻列表已运行 |
| 已有入口覆盖 | AmCham China 社会影响力 | 官网拒绝自动访问；邮件与认证公众号已覆盖 |
| 待解析器 | 中国残疾人福利基金会 | 采集客户端仍拿到验证页，不能稳定取条目 |
| 待访问复验 | 联合国儿童基金会驻华办事处 | 当前访问返回 403 |
| 待访问复验 | ReliefWeb | RSS 返回 HTTP 202 空内容，未取得有效条目 |
| 待解析器 | Candid | 旧 RSS 已重定向到 HTML 博客，需网页解析器 |

历史线索的“待核查”只表示曾在旧项目里出现。启用前仍要确认有效栏目、网络可访问、采集许可、日期、去重和内容范围。后台显示的 2026-10-08 网络探测是历史快照，不能当作今天仍可用的证据。

## 当前提示词覆盖范围

提示词不是一个文件，而是一条处理链：

| 阶段 | 主要文件 | 负责什么 |
| --- | --- | --- |
| 公益预筛 | `industry/prompts/prefilter.md` | 宽召回 PASS/BLOCK/UNKNOWN，不评质量 |
| 内容理解 | `understand.md` + `content-understanding.md` | 内容类型、作者角色、标签、编辑判断、中文标题摘要 |
| 领域语言 | `rules-domain.md` | 公益术语、机构正式名称、数字和法规原样保留 |
| 重要性评分 | `selection-score.md` | 按事件类型和五个维度生成 0–100 分 |
| 结构化 | `structure.md` | 提取人物、机构、地点、金额、时间等结构 |
| 事件归组 | `group-*.md` | 判断多篇文章是否属于同一事实 |
| 事件摘要 | `story-digest.md` | 合并同一事件的多来源信息 |
| 周报/月报 | `report-period.md` | 覆盖完整周期，合并重复事件，形成 4–8 个主题 |
| 翻译 | `translate-*.md` | 翻译海外公益内容，保持事实与引用 |

## 机构主题如何判定与清理误归类

“机构与平台”不是正文关键词搜索。结构化模型提出 `subjects` 后，后端还会做确定性校验：**信源的 `owner_entity_id` 等于该机构，或原始标题明确出现该机构在 `industry/taxonomy.ts` 登记的别名**，满足其一才进入机构主题。正文里顺带提及的合作方、资助方、嘉宾、获奖单位，以及周报、月报、年报、纪事和简报中的一条事项，都不能单独把整篇内容归给该机构。机构显示标签与 `subjects` 使用同一套结果，避免卡片标签和主题页相互矛盾。

`owner_entity_id` 只用于“该栏目每条内容都可视为该机构动态”的专属栏目。机构官网里的综合转载、中央文件转载、媒体聚合等宽栏目不能设置它，否则来源归属会被误当成文章主体；这类栏目仍可在标题明确点名机构时进入主题。当前 `web-mee-zcwj`（生态环境部 • 政策文件）因此不设运营主体 ID，环保要闻和新闻发布两个聚焦栏目继续保留。

出现串入时先核对来源的“运营主体 ID”和原始标题，不要靠手工删一张卡片掩盖规则问题。历史数据可在应用容器内执行：

```
node scripts/repair-entity-subjects.ts          # 只审计，输出数量和前 20 个样本
node scripts/repair-entity-subjects.ts --apply  # 修 analyses，并重建受影响 publications
```

脚本不调用模型，可重复运行。执行后检查所有 `group=company` 的主题页，重点看非本机构信源、合集标题和获奖名单；同时确认本机构自有信源仍保留。若规则需要回滚，恢复代码后重新分析相关材料；脚本直接修订过的历史 `analyses` 不自动保存旧数组，因此正式执行前应保留数据库备份。

当前公益预筛明确纳入：

- 公益、慈善、志愿服务、社会组织和基金会；
- 公益项目、募捐、捐赠和行业观点；
- 政府部门、公立学校、事业单位在慈善、社会组织、教育、乡村教育、学生资助、医疗健康、养老、儿童、残障、乡村、妇女儿童等领域的政策、解读、部署、通知和相关活动；
- 主体不是慈善机构但事件本身属于上述公共利益领域的内容；
- 标题已经明确公益相关但正文暂时缺失的内容。

明确压制或拦截：

- 普通企业经营、一般消费和泛社会新闻；
- 只在作者身份、来源标签或广告口号里出现“公益”的内容；
- 例行会务、表彰、参观座谈、普通人事、空泛项目再宣布；
- 没有项目细节和资金去向的营销募捐；
- 新闻合集、早报周报等没有单一焦点的打包材料；
- 无法识别、只有代词表情或“看图看视频”的材料进入 UNKNOWN，等待补材料。

重要性评分覆盖政策发布、政策分析、机构动态、项目进展、募集与数据、研究报告、一线故事、观点分析八类，内部按实质份量、信息增量、证据强度、读者共振和可行动性五轴加权。评分不是最终公开与否的唯一条件。

## 提示词范围仍待决策的缺口

下面不是已经批准的修改，而是当前代码与前台主题对照后发现的待校准项目：

| 范围 | 当前行为 | 为什么需要样本后再决定 |
| --- | --- | --- |
| 环境、气候、生态、气象 | 预筛明确规定：只有同时包含公益主体、公益项目、志愿或捐赠才 PASS；纯环境政策、监测、碳市场、生态治理、ESG 会 BLOCK | 前台已有“环境保护”主题，召回口径却更窄；放开后生态环境部三路来源会显著增加内容和模型费用 |
| 未成年人网络保护 | 前台有“网络保护”，预筛只通过“儿童”等上位词间接覆盖 | 需要区分儿童网络安全与一般互联网治理、游戏和平台新闻 |
| 青年发展 | 前台有“青年发展”，预筛未单独写明青年就业、创业、领导力 | 放宽可能混入普通招聘、创业和商业培训 |
| 亲子养育与家庭教育 | 前台有“亲子养育”，预筛通过教育和儿童间接覆盖 | 需要排除母婴营销、消费内容和泛育儿资讯 |
| 性别平等 | 前台有“性别平等”，预筛只明确“妇女儿童” | 需要界定公益行动、政策与泛文化争议的边界 |
| 营养健康 | 前台有“营养健康”，预筛包含医疗健康 | 需要区分儿童营养公益、公共健康项目与普通健康科普、商业医疗 |
| 应急救援 | 前台有“应急救援”，现有规则依赖公益项目、捐赠或相关公共部门语境 | 需要排除一般灾情快讯，同时保留公益响应、救援和灾后恢复 |
| 企业 ESG/可持续发展 | AmCham 邮件连接器会先按关键词保留，但全局预筛仍可能拦截普通企业绿色项目 | 需要决定 Yi-Hot 是关注公益交叉部分，还是扩大到全部 ESG |
| 国际人道与发展 | Oxfam、GiveDirectly、SSIR 已接入，UN 新闻暂停，ReliefWeb 待验证 | 需要平衡国际覆盖、中文读者相关性、翻译成本和重复国际新闻 |
| 养老、社区、行业治理 | 可进入公益预筛，前台主要由“其他领域”兜底 | 若内容量增长，是否从“其他领域”拆成独立前台主题需要负责人决定 |

调整这些范围前，项目负责人应各提供至少 10–20 条“应该纳入”和“不应该纳入”的真实样本，再修改预筛、理解提示、主题映射和测试。只在提示词里加一个关键词，往往会造成大量误收，不能作为完整修改。

## 每次扩展信息范围还要同步什么

新增一个领域不只改提示词，至少检查：

1. `prefilter.md` 是否允许召回；
2. `content-understanding.md` 和 `understand.md` 是否会生成一致标签；
3. `industry/taxonomy.ts` 是否有合适内容形态；
4. `industry/topics.json` 是否需要前台主题；
5. `industry/card-tags.ts` 是否有短标签和旧值兼容；
6. `selection-score.md` 是否会把该领域的正常事件误当噪声；
7. 来源清单是否提供足够正反样本；

8. 总报提示是否能正确合并该领域事件；
9. 现有历史内容是否需要回填；
10. 数据库 seed、审计快照、测试、重发布和线上抽样是否完成。

# 十七、未来同步 AIHOT 上游改动

## 当前状态

现有生产 `main` 与上游 `KKKKhazix/AIHOT` 已经明显分叉，不能直接把上游 `main` 合进当前生产分支，也不能用上游文件覆盖 Yi-Hot。这样做会破坏公益配置、数据库迁移、邮件、WeRSS、部署覆盖和现有历史。

仓库已经设计了隔离的上游对齐路线：

| 分支 | 用途 |
| --- | --- |
| `main` | 当前生产兼容版本，继续正常维护 |
| `vendor/aihot-main` | 上游 AIHOT 历史的只读镜像，只允许快进 |
| `rebuild/aihot-aligned` | 基于真实上游祖先重建的新 Yi-Hot |
| `chore/aihot-upstream-bootstrap` | 上游同步机制的审查分支 |

`vendor/aihot-main` **绝不能直接部署**，其中是上游示例行业和默认品牌，不是 Yi-Hot。

## 推荐的更新流程

1. 自动工作流或授权维护者只把公开上游快进到 `vendor/aihot-main`。
2. 阅读上游 changelog、迁移、依赖和安全相关改动，先决定哪些值得吸收。
3. 在 `rebuild/aihot-aligned` 合并 `vendor/aihot-main`，解决公共引擎与 Yi-Hot 扩展冲突。
4. 保留 `industry/`、品牌、来源、提示词、分类、邮件、公众号、用量管理和门户覆盖层。
5. 在全新测试数据库运行上游和 Yi-Hot 的全部迁移、测试与 smoke。
6. 用生产数据库备份副本彩排迁移，逐项对账文章、来源、总报、设置、人工覆盖和订阅。
7. 在 staging 验证 `/yihot/`、后台、API、RSS、邮件和 WeRSS。
8. 再用一个更新后的上游提交演练第二次合并，证明以后仍能持续更新。
9. 完整备份并验证回滚后，单独安排生产切换；不在同步工作流里自动部署。

对齐后的常规命令是：

```
git remote add upstream https://github.com/KKKKhazix/AIHOT.git
git fetch upstream main
git switch rebuild/aihot-aligned
git merge --no-ff upstream/main
```

这组命令只适用于上游对齐分支，**不要在当前生产 `main` 上执行**。

### 自动同步权限

GitHub Actions 若需要同步上游包含 `.github/workflows/` 的提交，普通 `GITHUB_TOKEN` 不够，需要仓库范围的 `AIHOT_SYNC_TOKEN`，至少具备 Contents 和 Workflows 的读写权限。使用短期 fine-grained PAT 或权限明确的 GitHub App，保存为 Actions Secret，不写入代码、文档或聊天。

没有这个 Secret 时，工作流可以只检查并提示有更新，不能声称已经完成同步。

### 决定是否值得同步

优先吸收安全修复、数据库正确性、采集稳定性、模型兼容性和显著性能提升。纯 AI 行业示例、上游品牌、默认来源和不适用于公益场景的功能不应迁入。

每次同步都记录：上游 commit SHA、选择吸收的功能、主动跳过的内容、数据库影响、验证结果和回滚点。完整方案见 `docs/AIHOT_UPSTREAM_REBUILD.md`。

## 十八、迁移到 NAS 或另一台服务器

### 能不能部署到 NAS

Yi-Hot 核心服务使用 Docker Compose，满足条件的 NAS 可以运行。当前整套生产还包含 WeRSS 和邮件 systemd 定时器，因此“核心站点能启动”不等于“全部功能已经迁移”。NAS 迁移需要逐项替代服务器能力。

### NAS 最低条件

- 支持 Docker/Container Manager 和 Compose；
- 建议至少 4GB 内存；若还要运行较多其他容器，建议 8GB；
- 至少 2 个 CPU 核心；
- 持久化存储建议预留 50GB，并启用磁盘健康和容量告警；
- 支持自动重启容器；
- 能配置域名、HTTPS 和反向代理；
- 能运行计划任务，或允许部署一个专门的定时任务容器；
- CPU 架构与所有镜像兼容。WeRSS 及其他第三方镜像尤其要核查 `amd64` / `arm64` 支持；
- 若放在家庭网络，必须考虑公网 IP、运营商入站限制、路由器端口转发和断电断网。

不建议把后台、PostgreSQL 或 WeRSS 管理端直接暴露到公网。

### 推荐迁移顺序

1. 记录当前镜像、compose 文件、环境变量名和 volume 清单。
2. 导出 PostgreSQL 逻辑备份，并实际恢复到一套临时数据库验证。
3. 备份 `/opt/yihot/.env`、Yi-Hot 数据 volume、`/opt/werss/.env` 与 data、邮件服务配置和游标。
4. 在 NAS 建立独立测试目录和 Docker 网络，不占用生产端口。
5. 先只部署 PostgreSQL、setup、API、worker、web，使用测试域名验证核心 Yi-Hot。

6. 再迁移 WeRSS，确认镜像架构、登录 Cookie、feed 和内部网络。
7. 把两个 systemd timer 改为 NAS 计划任务或定时任务容器；保持单实例运行，防止重复采集或发信。
8. 配置 HTTPS、备份、日志轮转、时间同步和重启策略。
9. 完成全量 smoke 后再切换 DNS/端口；腾讯云至少保留一个可回滚周期。

## NAS 上的目录建议

```
/volume/docker/yihot/
  app/                  仓库工作树
  env/yihot.env         主配置，权限仅管理员可读
  backup/postgres/      数据库备份
  email-source/         邮件采集配置与游标
  email-delivery/       邮件投递配置与游标
  werss/config/         WeRSS .env
  werss/data/           WeRSS SQLite、Cookie 和采集数据
```

实际路径随 NAS 品牌调整。不要把明文 `.env` 放进 NAS 的公开共享目录或自动同步到无加密的网盘。

## Compose 和定时任务适配

核心可以从 `docker-compose.yml` 开始，公众号采集再加入 `compose.werss.yml`。NAS GUI 导入 Compose 时要确认它没有改写 volume 名、网络名、健康检查或 `stop_grace_period`。

Synology/QNAP 等 NAS 未必使用 systemd。邮件采集、邮件投递和微信读书兼容任务可以用 NAS 计划任务调用一次性容器，或新增常驻调度容器。无论采用哪种方式，都要满足：

- 同一任务同一时刻只有一个实例；
- 配置和状态目录持久化；
- 失败返回非零并留下日志；
- 任务升级后仍保留游标；
- 时区明确，周报/月报边界仍按项目口径；
- 邮件和采集凭据不出现在命令行参数和可见日志中。

## HTTPS 与域名

推荐使用 NAS 自带反向代理或独立 Caddy/Nginx，将公网 HTTPS 转发到 web 容器。`SITE_URL` 必须改成最终公开地址，例如 `https://example.org/yihot`；若代理负责访客 IP，正确配置受信任代理后再开启 `TRUST_PROXY`。不要为了省事把数据库端口映射到公网。

路径仍必须保留 `/yihot/` 尾斜杠规则。

## NAS 迁移验收

- [ ] `/yihot/api/health` 返回数据库正常；
- [ ] 首页、动态、主题、详情和总报正常；
- [ ] 后台匿名访问跳转，正确密码能登录；
- [ ] 公开 API、RSS 和订阅页正常；

- [ ] worker 能完成一次采集和分析；
- [ ] WeRSS feed 和公众号原文链接正常；
- [ ] 两个邮件任务各运行一次且没有重复；
- [ ] 周报/月报时区和周期正确；
- [ ] 容器重启和 NAS 重启后数据、Cookie、游标、上传二维码仍存在；
- [ ] 数据库备份已在另一位置成功恢复；
- [ ] 旧服务器回滚步骤经过验证。

### 不建议迁移到 NAS 的情况

- NAS 只有 2GB 内存还要同时运行其他重服务；
- 使用 ARM CPU，但所需第三方镜像没有对应架构；
- 家庭网络经常断电、断网或没有可用入站连接；
- 没有异地备份；
- 无法限制管理端和配置目录权限；
- 无法提供稳定 HTTPS，或没有人负责系统和容器安全更新。

这种情况下继续使用云服务器，NAS 只承担加密备份，通常更稳妥。

## 十九、常见需求该改哪里

| 需求 | 首选入口 | 是否需要部署 |
| --- | --- | --- |
| 改关于页二维码 | 后台 → 设置 | 否，缓存后生效 |
| 开关飞书推送 | 后台 → 设置；凭据仍在 `.env` | 通常否；新增凭据需重建容器 |
| 调整付费调用次数上限 | 后台 → 设置 | 否 |
| 修改模型单价 | 后台 → 用量与成本 | 否 |
| 切换已有模型 | 后台 → 模型与评测 | 否；对应 Key 必须已配置 |
| 新增模型服务商 | 后端模型注册表和 `.env` | 是 |
| 新增 RSS/网站来源 | 后台 → 信源 → 新建 | 通常否 |
| 新增公众号 | WeRSS 添加账号，再在后台新增 RSS | 否；兼容层变化才部署 |
| 新增邮件简报 | 邮件白名单、解析测试、来源记录 | 是 |
| 修正一条标题或摘要 | 后台 → 内容诊断 | 否 |
| 批量修正日期/标签 | 一次性回填脚本和复核 | 是，先在备份副本试跑 |
| 新增公益领域或机构主题 | `industry/topics.json` 和相关映射 | 是，并 seed/迁移 |
| 改分类体系和提示词 | `industry/` 与样本测试 | 是 |

| 需求 | 首选入口 | 是否需要部署 |
| --- | --- | --- |
| 补历史周报/月报 | `scripts/recompose-period-history.ts` | 通常服务器执行，不改代码时无需构建 |
| 扩大发件规模 | 邮件投递器或专业邮件服务 | 是 |
| 修改后台密码或 API Key | 服务器 `.env` | 需要 `up -d` 重建配置 |
| 同步 AIHOT 新功能 | 上游隔离分支和 staging | 需要完整迁移与切换流程 |
| 搬到 NAS/新云服务器 | Compose、备份恢复、代理和定时任务 | 需要完整迁移 |

如果需求会改变分类、门槛、隐私条款、关注信源或品牌，由项目负责人先确认业务口径；如果只是修复明确故障、恢复服务或更新已批准来源，可以按本文流程直接处理。

## 二十、必须守住的安全边界

- 不提交 `.env`、`secrets/credentials.env`、邮箱授权码、后台密码、SSH 密码或 API Key。
- 不把生产密钥放入前端、浏览器存储、公开 API、Issue 或日志。
- 不直接改数据库日期、精选结果、费用或审计记录来掩盖问题。
- 不因一两次失败删除信源、内容或历史报告。
- 不在生产服务器保留没有回写仓库的临时代码修改。
- 不使用 `docker cp` 加 `restart` 作为正式部署。
- 不删除 Docker volume 解决普通启动问题。
- 不让测试访问真实模型、邮箱、飞书或生产数据库。
- 不绕过付费请求回执和预算熔断。
- 不让读者打开页面时触发模型调用。
- 不让前端直接读取数据库；公开出口使用统一 publication 读取层。
- 不开启全文展示，除非来源明确授权。
- 不删除 `LICENSE` 和 `NOTICE`，不使用 AIHOT 名称或 Logo 冒充官方项目。

## 二十一、专题文档索引

| 文档 | 用途 |
| --- | --- |
| `docs/PROJECT_CONTEXT.md` | 生产拓扑、内容口径、换机和接手 |
| `docs/HANDOFF-2026-10-17.md` | 最近一轮生产状态与历史决策 |
| `docs/memory/MEMORY.md` | 运维经验索引 |
| `docs/architecture.md` | 技术架构和数据流 |
| `docs/deploy.md` | 通用部署方式 |

| 文档 | 用途 |
| --- | --- |
| `docs/sources.md` | 信源类型与配置格式 |
| `docs/selection.md` | 评分和门槛校准 |
| `docs/AIHOT_UPSTREAM_REBUILD.md` | 上游 AIHOT 对齐、迁移和长期更新 |
| `docs/WERSS_DEPLOY.md` | 公众号采集和扫码恢复 |
| `docs/EMAIL_SOURCE_DEPLOY.md` | 邮件信源采集 |
| `docs/EMAIL_DELIVERY.md` | 公开订阅和邮件投递 |
| `tools/README.md` | 同步、部署和三方核查脚本 |
| `secrets/README.md` | 凭据加密、解密和换机 |

# 二十二、持续维护规则（Living Handbook）

> 本节自 2026-10-18 起适用，适用于本仓库的人工维护与 Codex、Copilot、其他 Agent 参与的后续改造。**这是协作规则，不是已部署的自动写作服务**：每次提交仍需由执行任务的人或 Agent 更新和复核；CI 通过不代表手册已自动更新。

## 文档分层：一份入口，一份总手册，专题按需深入

| 层级 | 维护目标 | 什么时候更新 |
| --- | --- | --- |
| `README.md` | 面向第一次访问仓库的人：定位、核心能力、展示图、演示与文档导航；保持精简 | 产品定位、主要功能或入口显著变化时更新 |
| **`MAINTENANCE.md`（本文件）** | **最详尽的可操作手册**：操作步骤、注意事项、故障树、例子、恢复方式、角色权限、操作验证 | 涉及用户行为、后台、信源、采集、标签、报告、订阅、成本、部署、测试、安全、交接的改动均应检查并更新 |
| `docs/*.md` 与 `docs/memory/*.md` | 源码结构、专题技术细节、故障证据、历史决策与用量快照 | 专题改造或产生新的可复用经验时更新；总手册要有入口 |
| `AGENTS.md`、`.github/copilot-instructions.md` | 告诉后续开发 Agent 必须检查哪些文档和安全边界 | 文档责任、工程流程或约定变化时更新 |

## 哪些变更必须同步到本手册

1. **功能与交互**：新增、删除或修改访客入口、后台开关、数据处理行为、API、订阅或退订路径时，修改对应章节的操作步骤；首次出现的新主题可以新增章节。

2. **数据与研究**：新增公益领域分类、救助儿童会研究/微信历史语料处理、标签规则、历史回填或质量检验时，记录**输入范围、方法、输出、样本量证据（若有）、局限及复核方法**。不要推定历史爬虫原始语料已经公开或已获得转载授权。
3. **信源与采集**：区分“历史候选”“人工批准”“运行时启用”“成功实采”；说明类型、配置、失败排查与来源权益。不要把 `industry/sources.json` 的行数写成运行时实际启用数。
4. **部署与安全**：更新环境变量名、服务依赖、数据库迁移、备份/恢复、腾讯云与 GitHub 一致性验证、故障处理。不得将明文密钥、真实个人邮箱清单或可识别隐私信息写入文档。
5. **CI、模型与费用**：测试规则或模型行为改变，要更新复现命令和验收标准；定价、用量、信源数等易变化指标**注明统计日期及证据源**，过期则保留为历史快照或替换，不能写成永久事实。

## 每次 PR、直接提交或部署的文档自检

- [ ] 先读取 `AGENTS.md` 与本手册相关章节，并核对实际代码/配置而不是凭回忆。
- [ ] 判断本次变更会否改变用户操作或维护方式；如会，更新 `MAINTENANCE.md` **对应章节**。技术细节较长时放到 `docs/`，在手册添加稳定链接。
- [ ] 如果新增故障修复：写明**现象 → 可能原因 → 核查命令 → 修复步骤 → 验证 → 回滚/风险**。
- [ ] 检查 README 的功能列表、截图、入口是否仍然真实；非重大变更不扩充 README。
- [ ] 将测试结果区分为**本地验证、GitHub Actions、腾讯云线上实测**；未实测的一律标“待验证”。
- [ ] 检查隐私、版权、上游 AIHOT 归属以及第三方 Logo 使用边界；不泄漏任何密钥。
- [ ] 在 PR 描述或交付说明中写“手册更新的位置”；如果确实不适用，写简短理由。**只改文档排版时通常无需扩写本手册。**

## 怎么记录长期变化而不把手册写乱

- **现行操作优先**：过时步骤直接修正并留下必要的迁移提示，避免堆积冲突版本；历史详证放到 `docs/HANDOFF-*.md` 或专题文件。
- **优先补证据而不是篇幅**：把“能做什么”写成可复核的点击路径、命令、样本或测试结果；没有证据的数字不应包装为成果。
- **按读者任务组织**：一项功能至少能回答“在哪里、怎么用、成功标准、失败怎么办、是否影响生产”。
- **避免重复**：详细故障日志和长命令可以放 `docs/`；此处保留必需操作和到原文的相对链接；每次新增都检查旧段落是否矛盾。
- **人机协作边界**：Agent 可以帮忙同步文档，但不能凭一次 Git 提交声称腾讯云已部署，也不能把仅存在于用户描述中的数据当成已核验的公开数据。

## 2026-10-18 维护基线

- `README.md` 已改为简短产品展示，原 1,518 行旧手册完整保存在本文件。
- GitHub `main` 的后端与 Docker CI 已修复并通过；该结论属于 **2026-10-18 的代码检查快照**，不代表腾讯云线上版本已比对一致。
- 救助儿童会方向有 13 个主题配置，详细代码为 `industry/save-the-children.ts`；历史微信文章采集与分析是独立研究工作，未经复核的样本总量不写成事实。

- 最近功能变化涉及邮件订阅、来源扩展和「其他领域」兜底标签，后续更新须优先检查 **第五、六、八、十一、十六章** 的操作步骤。

## 2026-10-18 本次维护变更

- 邮件订阅现在支持日报、周报、月报；活动订阅再次提交偏好时，必须通过新的确认邮件后才会更新，避免仅凭公开邮箱地址改动订阅。
- 日期只有来源日期而没有时刻时，数据库保存 `published_at_precision=date`，页面保留原文日期并用收录时刻显示排序；动态列表按展示时间倒序。
- Docker Compose 不再把 `.env` 全量注入 Web 容器；只有 setup、api、worker 读取服务端凭据。开发示例默认关闭采集和模型调用，生产启用前请显式设置安全阀并填写 `AIHOT_RELEASE`。